Programmation CUDA
Mémoire partagée, divergence, synchronisation

Oguz Kaya

Maître de Conférences
Université Paris-Saclay et l'Équipe ParSys du LRI, Orsay, France

université
PARIS-SACLAY

Objectifs

- Zoom sur l'architecture mémoire d'un GPU
- Utilisation de la "shared-memory" pour accès mémoire rapide
- Synchronisation de threads
- Concept de divergence pour la gestion efficace des branchements

Outline

Outline

Architecture mémoire d'un GPU

Il y a beaucoup de types de mémoire dans un GPU.

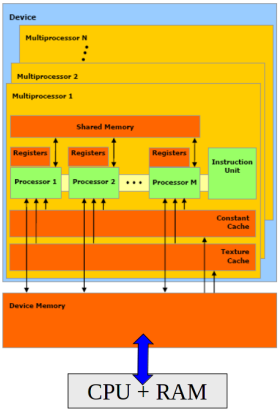

- Mémoire globale (RAM): 8-48Go, 500-2000 Go/s, 300-400 cycles par accès
- Registres: 65536/SM, acces immédiat (1/cycle)
- Cache L1: 64-192Ko/SM, $\approx$ 4 cycles par accès
- Cache L2: 8-40Mo, latence/bande passente pire que L1
- Constant cache: Mémoire constante par SM

Architecture mémoire d'un GPU

Il y a beaucoup de types de mémoire dans un GPU.

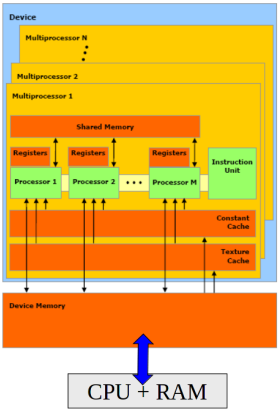

- Mémoire partagée (shared memory):
  - Partagée par tous les threads d'un bloc
  - 32-128Ko/SM
  - Technologie pareil que cache L1
  - Latence $\approx$ 4 cycles/accès
  - Bande passante comparable aux registres
  - Pas besoin de coalescence (aussi performant)
  - Peut se concurrencer avec la capacite du L1 (e.g., unified L1+shared memory)

Outline

Exemple: Calcul de puissance dans un tableau

Étant donné un tableau `A[N]` et un entier `k`, mettre `A[i]` au `A[i]`^{k}.

```
#include <cstdio>
#include "cuda.h"

#define N 1024
#define BLOCKSIZE 128
float A[N];

__device__ float dA[N];

__global__ void powerArray(int n, int k)
{
  int i = threadIdx.x + blockIdx.x * blockDim.x;
  if (i < n) {
    float c = 1.0;
    for (int j = 0; j < k; j++) { c *= dA[i]; }
    dA[i] = c;
  }
}

int main(int argc, char **argv)
{
  // Initialisation
  for (int i = 0; i < N; i++) { A[i] = i; }
  // Copier le tableau vers le GPU
  cudaMemcpyToSymbol(dA, A, N * sizeof(float), 0,
      cudaMemcpyHostToDevice);
  int blockSize = 128;
  int numBlocks = N / blockSize;
  if (N % blockSize) numBlocks++;
  powerArray<<<numBlocks, blockSize>>>(N, 4);
  // Recopier le tableau vers le CPU
  cudaMemcpyFromSymbol(A, dA, N * sizeof(float), 0,
      cudaMemcpyDeviceToHost);
  printf("%lf\n", A[2]);
  return 0;
}
```

- Blocs/threads 1D
- Chaque thread met à jour 1 élément avec k multiplications
- $dA[i]$ est accédé k fois. Peut-on faire mieux?
  - Mettre $dA[i]$ dans un registre (i.e., `float temp = dA[i];`)
  - Utiliser la mémoire partagée

Exemple: Calcul de puissance dans un tableau

Étant donné un tableau `A[N]` et un entier `k`, mettre `A[i]` au `A[i]`^{k}.

```
#include <cstdio>
#include "cuda.h"

#define N 1024
#define BLOCKSIZE 128
float A[N];

__device__ float dA[N];

__global__ void powerArray(int n, int k)
{
  int i = threadIdx.x + blockIdx.x * blockDim.x;
  // BLOCKSIZE == blockDim.x
  __shared__ float data[BLOCKSIZE];
  if (i < n) {
    data[threadIdx.x] = dA[i];
    float c = 1.0;
    for (int j = 0; j < k; j++) {
      c *= data[threadIdx.x];
    }
    dA[i] = c;
  }
}

int main(int argc, char **argv)
{
  /// ...
  powerArray<<<numBlocks, blockSize>>>(N, 4);
  /// ...
  printf("%lf\n", A[2]);
  return 0;
}
```

- Le préfixe **__shared__** pour définir un tableau en shared memory
- La taille doit être une **constante** connue en temps de compilation (donc impossible d'utiliser **blockDim.x**)
- `dA[i]` est accédé **1 fois** puis réutilisé **k fois** en shared memory.
- Tableau est libéré quand le bloc termine donc pas besoin de **désallouer**.

Outline

Branchements dans un kernel GPU

Les threads sont exécutés par des groupes de 32 dans un **warp**.

- Tous les threads exécute la même instruction simultanement.
- S'il y a un **branchement**: `if (cond) f(); else g();`
  - Si tous les threads dans un warp satisfont **cond**, ils exécutent seulement `f()` simultanement.
  - Si tous les threads dans un warp echouent **cond**, ils exécutent seulement `g()` simultanement.
  - S'il y a **au moins un thread** qui satisfait **cond** et **au moin un threads** qui échoue **cond**
    - D'abord `f()` est exécutée par ceux qui satisfont **cond**, le reste s'endorment.
    - Après `g()` est exécutée par ceux qui échouent **cond**, le reste s'endorment.
    - Le temps total d'exécution du warp est donc la somme des deux.

Exemple: Deux types de divergences

Étant donné un tableau `A[N]` et un entier `k`, mettre `A[i]` au `A[i]`^{k}.

```
__device__ void kernel()
{
  // ...
  // Divergence 1
  if (threadIdx.x % 2 == 0) {
    f();
  } else {
    g();
  }
  // ...
  // Divergence 2
  if (threadIdx.x < SIZE / 2) {
    f();
  } else {
    g();
  }
  // ...
}
```

- Supposons $f()$ et $g()$ prennent F et G secondes respectivement dans l'exécution par un thread.
- Divergence 1 concerne **tous les warps**, donc le temps total d'exécution de chaque warp sera $F + G$.
- Divergence 2 concerne **un seul warp** parmi tous, chaque autre warp prend soit F soit G secondes dans l'exécution.

Exemple: Deux types de divergences

Étant donné un tableau `A[N]` et un entier `k`, mettre `A[i]` au `A[i]`^{k}.

```
__device__ void kernel()
{
  // ...
  // Divergence 1
  if (threadIdx.x % 2 == 0) {
    f();
  } else {
    g();
  }
  // ...
  // Divergence 2
  if (threadIdx.x < SIZE / 2) {
    f();
  } else {
    g();
  }
  // ...
}
```

- Pour de bonnes performances, il faut
  - soit éviter les branchements au maximum
  - soit les réaliser de manière que peu de warps divergent dans l'exécution.

Contact

Oguz Kaya
Université Paris-Saclay and LRI, Paris, France
oguz.kaya@lri.com
www.oguzkaya.com